

SETUP · API GRATIS

NVIDIA Build

Configura tu API key gratis y conecta 80+ modelos de IA a Cursor y Claude Code.

Kimi, DeepSeek, GLM, MiniMax, GPT-OSS. Sin tarjeta.

- 1 Crea tu cuenta gratis en build.nvidia.com
- 2 Genera tu API key personal (empieza con nvapi-)
- 3 Conéctala a Cursor en 5 minutos
- 4 Conéctala a Claude Code con un proxy LiteLLM
- 5 Elige el modelo correcto según tu tarea
- 6 Evita los errores más comunes (401, 429 y fallos de formato)

Qué es: Build by NVIDIA (build.nvidia.com) es el portal donde NVIDIA expone su catálogo de modelos NIM (NVIDIA Inference Microservices) al público. Te registras, generas una API key y usas modelos de código abierto de primer nivel gratis, sin tarjeta de crédito.

PASO 1

Crea tu cuenta y genera tu API key

Todo el proceso toma menos de cinco minutos y no requiere método de pago. Necesitas un correo electrónico; algunos usuarios reportan que también se pide verificar un número de teléfono, dependiendo de la cuenta.

1 REQUISITOS

Correo electrónico para crear la cuenta. Posiblemente verificación de teléfono (no siempre se pide). No se solicita tarjeta de crédito en ningún punto del proceso gratuito.

El tier gratuito tiene un límite compartido de aprox. 40 solicitudes por minuto en tu API key, sin importar cuántos modelos uses en paralelo.

TIEMPO: 1 MIN

2 CREA TU CUENTA

Entra a build.nvidia.com y regístrate con tu correo (esto te inscribe en el NVIDIA Developer Program, que es gratuito). Confirma tu correo para activar la cuenta.

TIEMPO: 2 MIN

3 GENERA TU API KEY

Entra primero al catálogo de modelos para elegir con cuál quieres empezar. Desde ahí mismo puedes generar tu key con "Generate API Key". Dale un nombre (ej. "mi-proyecto") y opcionalmente configura una fecha de expiración.

build.nvidia.com/models

Copia la key de inmediato: empieza con nvapi- y solo se muestra una vez. Si la pierdes, tienes que generar una nueva — no hay forma de recuperarla.

TIEMPO: 1 MIN

PASO 2

Conéctala a Cursor (la más fácil)

Cursor acepta cualquier endpoint compatible con la API de OpenAI, y el endpoint de NVIDIA Build habla ese formato de forma nativa. Por eso esta es la integración más directa: dos campos y listo.

1 ABRE LA CONFIGURACIÓN

Abre Cursor → Settings → Models. Ahí verás la lista de modelos por defecto y, más arriba, el campo para agregar un proveedor personalizado.

TIEMPO: 30 SEG

2 ACTIVA EL OVERRIDE

Activa el toggle "Override OpenAI Base URL" y pega la URL base de NVIDIA. Debajo, en "OpenAI API Key", pega tu key (aunque el campo diga OpenAI, el key se envía al endpoint que pusiste arriba).

```
Override OpenAI Base URL:  
https://integrate.api.nvidia.com/v1
```

```
OpenAI API Key:  
nvapi-tu-key-aqui
```

TIEMPO: 1 MIN

3 AGREGA EL MODELO

Con "+ Add Model" escribe el identificador exacto del modelo que quieres usar, tal como aparece en el catálogo de build.nvidia.com/models (incluye el prefijo del publisher).

```
moonshotai/kimi-k2.5  
deepseek-ai/deepseek-v3.2
```

Cursor envía el string del modelo tal cual al endpoint. Si el nombre no coincide exactamente con el catálogo de NVIDIA, obtienes error "model not found".

TIEMPO: 30 SEG

PASO 3

Conéctala a Claude Code (con proxy)

Claude Code habla el formato Anthropic Messages API (/v1/messages). El endpoint público de NVIDIA Build solo habla el formato de OpenAI (/v1/chat/completions). Por eso las dos variables básicas NO bastan aquí — necesitas un traductor en medio.

1 POR QUÉ EL MÉTODO DIRECTO FALLA

Si solo defines ANTHROPIC_BASE_URL y ANTHROPIC_API_KEY apuntando al endpoint de NVIDIA, Claude Code arranca pero las llamadas fallan o se rompen en el uso de herramientas: está mandando peticiones en un formato que NVIDIA no entiende.

La solución real es un proxy que traduce entre ambos formatos. El más usado para esto es LiteLLM, un gateway open source que corre en tu máquina.

TIEMPO: LECTURA

2 INSTALA Y CONFIGURA EL PROXY

Instala LiteLLM con soporte de proxy y crea un archivo config.yaml que mapea un nombre de modelo al endpoint de NVIDIA, usando el prefijo nvidia_nim/.

```
pip install 'litellm[proxy]'

# config.yaml
model_list:
  - model_name: kimi-nvidia
    litellm_params:
      model: nvidia_nim/moonshotai/kimi-k2.5
      api_key: os.environ/NVIDIA_API_KEY
      api_base: https://integrate.api.nvidia.com/v1
litellm_settings:
  drop_params: true
```

drop_params: true es clave — Claude Code manda parámetros específicos de Anthropic que los modelos de NVIDIA no reconocen, y esta línea los descarta en silencio en vez de tronar.

TIEMPO: 3 MIN

PASO 3 · CONTINUACIÓN

Levanta el proxy y lanza Claude Code

1 LEVANTA EL PROXY

En una terminal, exporta tu key de NVIDIA y arranca LiteLLM apuntando a tu config.yaml. Déjalo corriendo en esa terminal.

```
export NVIDIA_API_KEY="nvapi-tu-key-aqui"
litellm --config config.yaml --port 4000
```

TIEMPO: 30 SEG

2 APUNTA CLAUDE CODE AL PROXY

En otra terminal, redirige Claude Code hacia tu proxy local en vez de a Anthropic, y corre claude como siempre.

```
export ANTHROPIC_BASE_URL="http://localhost:4000"
export ANTHROPIC_API_KEY="sk-cualquier-valor"
export ANTHROPIC_MODEL="kimi-nvidia"
claude
```

Alternativa sin configurar nada a mano: el proyecto open source "free-claude-code" (github.com/Alishahryar1/free-claude-code) empaqueta este mismo proxy con una interfaz de administración local — pegas tu key de NVIDIA y listo.

TIEMPO: 1 MIN

REFERENCIA RÁPIDA

Modelos y errores comunes

El catálogo de NVIDIA cambia seguido — modelos se agregan, se renombran o se retiran. Antes de construir algo sobre un modelo específico, confirma el identificador exacto en [build.nvidia.com/models](#).

MODELOS RECOMENDADOS SEGÚN LA TAREA

Código / tareas agénticas
moonshotai/kimi-k2.5, deepseek-ai/deepseek-v3.2

Documentos largos / contexto extenso
Kimi K2.5 (contexto de 200k tokens)

Multilinguaje
GLM 5.1

Razonamiento puro
MiniMax M2.7

Uso general / gratis y rápido
GPT-OSS-120B

ERRORES COMUNES

Error 401 (no autorizado):
tu key está mal copiada, tiene espacios de más o expiró. Genera una nueva desde [build.nvidia.com/models](#).

Error 429 / respuestas lentas:
le estás pegando a un modelo popular y saturado, o superaste las ~40 solicitudes por minuto de tu key. Prueba un modelo menos usado o espera unos segundos.

Claude Code no responde bien / falla en herramientas:
casi siempre significa que estás usando las variables básicas sin proxy. Revisa el Paso 3 — necesitas LiteLLM (o free-claude-code) traduciendo el formato.

"Model not found" en Cursor o en el proxy:
el identificador del modelo no coincide exactamente con el catálogo. Cópialo tal cual aparece en [build.nvidia.com/models](#), incluyendo el prefijo del publisher.

Nos vemos adentro.

Sigue aprendiendo IA gratis.

Esta guía es el punto de partida. En The Grid encuentras tutoriales paso a paso, workflows reales usados en proyectos con clientes, y una comunidad activa en español que aprende IA junto contigo. Todo gratis.

COMUNIDAD · THE GRID

Únete gratis a la comunidad

Tutoriales, workflows reales, recursos y builders en español aprendiendo IA juntos.

skool.com/the-grid-5633

Diego · @ortegoat

Co-fundador de The Grid

Educación práctica en IA para negocios en español.

→ Instagram: [@ortegoat](https://twitter.com/ortegoat)

→ Web: ortegoat.com

→ Comunidad: the-grid.mx